



Reconhecimento de Espécies Florestais Utilizando Visão Computacional

Recognition of Forest Species Using Computer Vision

Marcos Kai Chiun Huang *, Gustavo Silva Quierregato[†], Thiago Franca Naves[‡],
Pedro Luiz de Paula Filho[§]

RESUMO

O processo de identificação e classificação de espécies florestais é realizado por meio das características existentes nos troncos das árvores, às quais muitas destas espécies podem ser encontradas na floresta amazônica. Este artigo tem como objetivo apresentar o desenvolvimento de uma arquitetura capaz de realizar tal processo, utilizando uma Rede Neural Convolucional Resnet50, ao qual já se encontra pré-treinada. A base de dados utilizada possui 48 classes dos principais tipos de madeira existentes, para realizar o processo foi necessário que houvesse uma separação entre treino e teste, ao qual se obteve 70% para treinamento e 30% para teste, garantindo que o modelo possa extrair o máximo de características possíveis

Palavras-chave: Big Data. Aprendizado de Máquina. Processamento de Dados. Cooperativa. Agroindustrial.

ABSTRACT

The classification process of forest species is carried out through the structure belonging to the trunks of each one, which is the best parameter for identification. This article presents the development of an architecture for the recognition and classification of the main forest species using Computer Vision. The model uses a pre-trained Neural Network to carry out the identification process. The present database has a total of 48 classes, 70% of which are for training and the other 30% for testing.

Keywords: Big Data. Machine Learning. Data Processing. Cooperative. Agroindustrial.

1 INTRODUÇÃO

O Brasil é conhecido mundialmente pela as suas extensas áreas florestais nativas. Contendo uma quantidade significativa da diversidade global de fungos e plantas (9,5% e 9,9%), além disso possui um dos maiores índices de endemismo (46,2%) no planeta, composta por 18.932 espécies endêmicas. (AL., 2020)Entretanto, várias espécies vegetais brasileira está com risco de extinção causada por das destruições e fragmentação dos habitats das espécies. Por isso, a identificação correta das espécies é importante para evitar comércios e extrações ilegais de madeira, e evita extinção de varias especie. (PRABU RAVINDRAN BLAISE J. THOMPSON, 2020)

* Coordenação de Ciência de Computação; ✉ marcoshuang@alunos.utfpr.edu.br; <https://orcid.org/0000-0000-0000-0001>.

† Cordenação de Ciência de Computação; ✉ quierregato@alunos.utfpr.edu.br; <https://orcid.org/0000-0000-0000-0000>.

‡ Coordenação de Ciência de Computação; ✉ naves@utfpr.edu.br; <https://orcid.org/0000-0002-3152-1197>.

§ Acadêmico em Ciência de Computação; ✉ pedrol@utfpr.edu.br; <https://orcid.org/0000-0000-0000-0000>.



O reconhecimento de espécies florestais, através de madeiras, são feitas por especialistas bem treinados em identificação de espécies florestais, e em laboratórios específicos. Entretanto, atualmente existem muito impasses nessas atividades, tais como, leva-se muito tempo para tornar-se um especialista para identificar espécies, com isso os profissionais dessa área são muito escassos, ademais, é muito subjetivo alguém identificar uma madeira através de textura, pois as espécies são naturalmente parecidas. Na qual, no Brasil existem poucos laboratórios especializados.(OLIVEIRA, 2018) Xiloteca é uma coleção de amostras de madeiras obtidas, catalogadas e armazenadas. Ao analisar as camadas macroscópicas e microscópicas, percebe-se que cada espécie de madeira possui diferentes padrões morfológicos, o que possibilita utilizar técnicas de visão computacional para o reconhecimento de padrões.()

Nos últimos anos, o problema de reconhecimento de espécies florestais é tratado na visão computacional utilizando abordagem focada em textura, ou seja, tratava-se da diferença de intensidade das cores dos pixels vizinhos numa imagem 2-D, que separa o objeto que deseja reconhecer do fundo. As técnicas utilizadas principalmente foram de Gray Level Co-occurrence Matrix (GLCM), Local binary pattern (LBP), e Compound Local Binary Pattern (CLBP). Como o estudo desta área é recente, e com a dificuldade de obtenção de base de dados, foi utilizado neste projeto uma base de imagens próprias, com o objetivo de utilizar uma abordagem de aprendizagem profunda para reconhecimento de imagens, as redes neurais (PAULA FILHO, 2012).

2 BASES DE DADOS E PROPRIEDADES DA IMAGEM

Um dos impasses para o reconhecimento de espécies florestais está na dificuldade em obter uma base de imagens capaz de atender a todos os requisitos de treinamento, tornando a taxa de erro cada vez mais baixa. **(Isto acontece, devido aos custos elevados dos equipamentos para aquisição de imagens, dificultando a preparação das amostras do material a ser utilizado, neste caso a madeira.)** Isso acontece por causa dos custos elevados dos equipamentos de aquisição que dificulta a preparação das amostras das madeiras, e consequentemente reduz a quantidade de pesquisa na área. (PAULA FILHO, 2012)

Primeiramente, foram selecionados 30 amostras de bloco de madeiras similares entre as espécies, selecionados por profissionais que têm experiências em anatomia de madeira, após isso, para que tornarem uniformes, as amostras foram lixadas em um tamanho 2cm³. Portanto, as imagens macroscópicas e microscópicas foram retiradas das fotografias do plano transversal dos blocos de madeiras, obtidas pelo Laboratório de Anatomia de Madeira da Universidade Federal do Paraná.(PAULA FILHO, 2012)

As fotos macroscópicas para construção da base de imagens deste trabalho seguem o protocolo do trabalho de Martins (2015), na qual para simular um ambiente florestal, foi necessário a utilização de equipamentos não profissionais e menor qualidade, como serra, lixa grossa, e lixa fina. E o qualificado e da luminosidade não controlado dos ambientes. Portanto, foi criado um procedimento no ambiente, como padronização da luminosidade e da distância dela, para realizar tal procedimento foi construído um ambiente controlado, cujo mesmo utiliza de 2 (duas) lâmpadas para halógenas e um filtro de papel sulfite, permitindo que a iluminação fosse distribuída igualmente, para retirar as fotos foi utilizada de uma câmera SONY, cujo modelo é descrito como DSC T20.(PAULA FILHO, 2012)

A base atual foi construída em conjunto com a Polícia Florestal que auxiliou na retirada das amostras de imagens macroscópicas e microscópicas, contando com 48 classes diferentes de estruturas de madeira, como apresentadas alguns exemplos no Quadro 1.

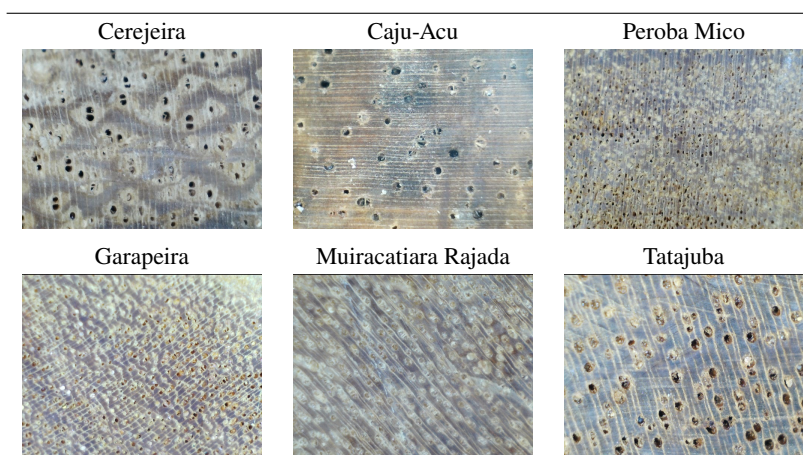
Quadro 1 Exemplos de imagens e classes de espécies florestais. –



Tabela 1 – Tabelas com os nomes populares e científicos das espécies

Nome Popular	Nome Científico
Acrocarpus	Acrocarpus fraxinifolius
Amapá	Brosimum paraensis
Andiroba	Andiroba
Angelim Pedro	Hymenolobium petraeum
Araucária	Araucaria angustifolia
Assacu	Hura crepitans

Fonte: Autoria própria (2021).



Fonte: (Liong19).

3 METODOLOGIA PARA CLASSIFICAÇÃO DE ESPÉCIES FLORESTAIS


Sendo um dos modelos computacionais mais utilizados atualmente e também mais indicados para classificação de imagens utilizando camadas profundas, a ResNet50 possui uma camada de entrada com tamanho de 224x224 e também é composta pela arquitetura apresentada na Figura 1, este modelo permite ao usuário trabalhar com uma rede pré-treinada, que por meio de pesos adicionais com a ImageNet que possuem milhões de imagens, será possível obter um conjunto maior de informações sobre a classe presente, tornando então o processo de treinamento ainda mais eficaz.

A combinação de camadas convolucionais aplicadas ao modelo proposto, permitem que se trabalhe com 64 filtros nas camadas convolucionais e pooling com janelas de tamanho 3x3 e stride de 2, seguida de camadas interconectadas, contando com 32 filtros de tamanho 3x3 e stride 1. Ao final o mesmo conta com camada de saída totalmente conectada e que podem depender da quantidade de classes ao qual se está realizando o processo de treinamento. (LUIZ HAFEMANN LUIZ OLIVEIRA, 2014)

Por meio de um conceito já aplicado em diversos treinamentos de redes neurais, foi utilizado de *Transfer Learning* ao qual permite que o engenheiro de Machine Learning treine seu modelo utilizando camadas pré-treinadas com padrões já reconhecidos e devidamente comprovados, este conceito tem como finalidade otimizar o desempenho e também tornar a convergência para o resultado ainda mais rápida. (OLIVEIRA, 2018)

O aumento de informações estão se mostrando muito eficazes, onde se tem por exemplo uma imagem com tamanho previamente extenso e deseja dividir a mesma em partes, tornando o conjunto maior e também obtendo então um detalhamento sobre as características existentes muito maior.

Afim de tornar o conjunto maior e utilizar deste conceito, foi realizado o processo de redimensionamento das



Fonte: (LUIZ HAFEMANN LUIZ OLIVEIRA, 2014)

imagens existentes, fotos macroscópicas com dimensões de 2068x1530 puderam ser subdivididas em imagens microscópicas de 640x480 pixels. O tamanho do lote foi configurado de forma a mudar cada vez em que uma etapa é concluída, ou seja, tornando a quantidade de amostras utilizadas para realizar o treinamento fosse alterado. (OLIVEIRA, 2018)

O método apresentado tem por finalidade tornar o modelo ainda mais eficaz de identificar cada espécie florestal e por fim conseguir parâmetros de arquitetura com percentuais melhores a cada treinamento.

4 EXPERIMENTOS E ANÁLISE DOS RESULTADOS

O treinamento foi realizado por meio de fotos macroscópicas e microscópicas que permitem identificar características existentes na estrutura celular da madeira, que ao final da geração do conjunto de dados foi realizado o processo de criação de um local de virtualização ao qual permite ao usuário que estiver utilizando de seus recursos, realizar processos que muitas das vezes não poderiam ser executadas em computadores convencionais mais simples. Sendo assim o COLAB, que foi desenvolvido pelo Google e possui uma gama de recursos como, GPU (Graphics Processing Unit), memória virtualizada, e até mesmo TPU (Tensor Processing Unit). O mesmo permitiu que a classificação do modelo fosse realizada, por meio da utilização da Resnet50, utilizando em conjunto bibliotecas como OpenCV, Numpy, Tensorflow tanto para importação das funções responsáveis pela inicialização dos gerados, que permitem retornar apenas uma instância dos dados enviados para a função, utilizando apenas a memória suficiente para o treinamento. Também foram utilizados, Keras, Sklearn, Albumentation e Neural Struct Learng. Foram utilizadas de duas bases diferentes, as quais eram separadas tanto por um conjunto de



imagens macroscópicas e microscópicas, tornando possível a comparação com trabalhos que utilizam do mesmo tipo de separação.

Tabela 2 – Base de dados utilizando fotos microscópicas

Base de dados microscópicas 70/30		
Épocas	Acurácia de treino	Acurácia de teste
1	99,72%	99,43%
2	100%	99,43%
3	100%	99,43%

Tabela 3 – Base de dados utilizando fotos macroscópicas

Base de dados Macroscópicas 70/30		
Épocas	Acurácia de treino	Acurácia de teste
1	99,94%	93,65%
2	100%	93,94%
3	100%	93,94%
4	100%	99,12%

Os resultados apresentados na 3 4 mostram que o conjunto de dados utilizando fotos microscópicas obtiveram um resultado positivo sobre o conjunto mais amplo, permitindo que a rede identificasse por meio destas as características necessárias para a classificação.

O uso de uma rede pré-treinada também possibilitou que o modelo obtivesse padrões mais detalhados, com isso o mesmo conseguiu utilizar os pesos para chegar ao objetivo descrito no início deste trabalho.

Após o fim do treinamento foram observadas alguns parâmetros importantes, bem como a acurácia e o erro, que seriam essenciais para saber se o conjunto precisaria ou não de uma nova etapa de remodelagem, com isso, gerado também a matriz de confusão para identificar a capacidade de classificação das imagens com verdadeiros e falsos (positivos e negativos).

De acordo com 4 é possível visualizar que o percentual de acurácia no conjunto de treinamento obteve um valor de 100% de acerto logo na 2 (segunda) época, mostrando que a mesma convergiu rapidamente para o valor descrito, enquanto o percentual de teste também obteve um percentual de acurácia elevado na base de testes, chegando a um valor de 99,43%. Na amostra utilizando fotos macroscópicas (3), percebe-se que também houve a convergência na segunda época, entretanto, utilizando a base de teste se manteve, deixando o percentual de acerto sobre a base de teste de 99,12% na 4 (quarta) época.

5 CONCLUSÃO

Este trabalho apresentou uma arquitetura de reconhecimento de classificação de espécies florestais em fotos macroscópicas utilizando Visão computacional e Aprendizado Profundo. A arquitetura utiliza a rede neural Resnet50 pré-treinada, utilizando *Data augmentation* e treinamento com validação do modelo.

Nos experimentos foi utilizada uma base de imagem de espécies separadas ao qual foi selecionada uma imagem por espécie. Segundo os resultados apresentados, o modelo foi capaz de realizar a identificação das espécies de forma a aprender as principais características de cada uma. A acurácia e o erro apresentado foram satisfatórios possibilitando a aplicação de futuros testes utilizando a identificação e ampliação de espécies florestais.



AGRADECIMENTOS

Ao Laboratório de Aprendizado de Máquina e Imagens Aplicados a Indústria - LAMIA¹, por toda a orientação e suporte. A Universidade Tecnológica Federal do Paraná e a Fundação Araucária, pela concessão de bolsa de pesquisa.

REFERÊNCIAS

- AL., Deivison Venicio Souza at. An automatic recognition system of Brazilian flora species based on textural features of macroscopic images of wood, 2020.
- LUIZ HAFEMANN LUIZ OLIVEIRA, Paulo Cavalin. Forest Species Recognition Using Deep Convolutional Neural Networks. **IEEE**, IEEE, v. 6, n. 4, p. 1104–1106, 2014.
- OLIVEIRA, Wellington. **Software para reconhecimento de espécies florestais a partir de imagens digitais de madeiras utilizando deep learning**. 2018. Diss. (Mestrado) – Universidade Tecnológica Federal do Paraná.
- PAULA FILHO, Pedro Luiz de. Reconhecimento de espécies florestais através de imagens macroscópicas, 2012.
- PRABU RAVINDRAN BLAISE J. THOMPSON, Richard K. Soares. The XyloTron : Flexible , Open-Source , Image-Based Macroscopic Field Identification of Wood Products, 2020.

¹ <https://www.lamia.sh.utfpr.edu.br/>